

1. Yönetici Özeti

Bu çalışma, bir bankanın müşteri tabanında hangi müşterilerin yakın gelecekte bankadan ayrılma (churn) eğiliminde olduğunu önceden tahmin etmeyi amaçlayan, uçtan uca bir makine öğrenmesi projesidir. Proje, CRISP-DM metodolojisinin altı aşamasının tamamını (İş Problemi, Veriyi Tanıma, Veri Hazırlama, Modelleme, Değerlendirme ve Deployment) sistematik biçimde uygulamaktadır.

10.000 müşteri ve 14 değişken içeren veri seti üzerinde yürütülen keşifsel analiz; yaşı, üyelik aktifliğinin, müşterinin bulunduğu ülkenin ve sahip olunan ürün sayısının ayrılma davranışını belirleyen temel etkenler olduğunu ortaya koymuştur. Veri, sızıntıyı (data leakage) önleyen bir pipeline ile hazırlanmış, 16 farklı sınıflandırma modeli aynı koşullarda karşılaştırılmış ve çok kriterli bir değerlendirme sonucunda Lojistik Regresyon nihai model olarak seçilmiştir.

Nihai model, test kümesindeki gerçek churn vakalarının **%67,2'sini (Recall)** doğru biçimde yakalamakta ve **0,76 ROC-AUC** değerine ulaşmaktadır. Model, çalışan bir Streamlit arayüzü ile ürünleştirilmiş; kullanıcının müşteri bilgilerini girip anlık churn riski tahmini alabildiği bir karar destek aracına dönüştürülmüştür. Sonuç olarak banka, ayrılma riski yüksek müşterileri önceden tespit ederek hedefli elde tutma (retention) kampanyalarıyla müşteri kaybını azaltabilir.

2. İş Problemi (Business Understanding)

Bankacılık sektöründe yeni bir müşteri kazanmanın maliyeti, mevcut bir müşteriyi elde tutmanın maliyetinden kat kat yüksektir. Bu nedenle müşteri kaybını (churn) azaltmak, doğrudan kârlılığa etki eden stratejik bir önceliktir. Ancak bir müşteri ayrıldıktan sonra atılacak adımın değeri yoktur; kritik olan, müşterinin ayrılma kararını vermeden önce risk taşıdığının fark edilmesidir.

Bu projenin çözmeye çalıştığı temel karar sorusu şudur: *“Hangi müşteriler ayrılma riski taşıyor ve banka, sınırlı elde tutma bütçesini öncelikli olarak kime yönlendirmeli?”* Geliştirilen model bu soruya olasılık temelli bir yanıt vererek, pazarlama ve müşteri ilişkileri ekiplerinin proaktif aksiyon almasını sağlar.

Başarı Kriteri

Başarı kriteri, model kurulmadan önce belirlenmiştir. Bu problemde asıl maliyet, gerçekten ayrılacak bir müşteriyi “kalır” diye sınıflandırmaktır (yanlış negatif / False Negative): bu müşteri hiçbir müdahale görmeden kaybedilir. Buna karşılık, kalacak bir müşteriyi yanlışlıkla “riskli” işaretlemek (yanlış pozitif / False Positive) yalnızca gereksiz bir kampanya teklifine yol açar ve görece ucuzdur. Bu asimetri nedeniyle modelin başarısı tek başına doğruluk (accuracy) ile değil, öncelikle Recall (yakalama oranı) ve F1 skoru ile ölçülmüştür.

3. Veri Seti ve Metodoloji

Çalışmada, bir bankanın 10.000 müşterisine ait 14 değişkenlik veri seti kullanılmıştır. Hedef değişken, müşterinin bankadan ayrılıp ayrılmadığını gösteren ikili (binary) Exited değişkenidir (1 = ayrıldı, 0 = kaldı). Veri setindeki churn oranı yaklaşık %20 olup, bu durum hafif bir sınıf dengesizliği yaratmaktadır.

Değişken	Tip	Açıklama
----------	-----	----------

CreditScore	Sayısal	Kredi skoru (350–850)
Geography	Kategorik	Ülke: Fransa / Almanya / İspanya
Gender	Kategorik	Cinsiyet
Age	Sayısal	Yaş (18–92)
Tenure	Sayısal	Bankada kalma süresi (yıl)
Balance	Sayısal	Hesap bakiyesi
NumOfProducts	Sayısal	Kullanılan ürün sayısı (1–4)
HasCrCard	İkili	Kredi kartı sahipliği
IsActiveMember	İkili	Aktif üye mi
EstimatedSalary	Sayısal	Tahmini yıllık maaş
Exited (HEDEF)	İkili	Ayrıldı (1) / Kaldı (0)

Metodoloji olarak CRISP-DM (Cross Industry Standard Process for Data Mining) çerçevesi benimsenmiştir. Bu çerçeve, ham veriden iş kararına uzanan süreci altı yinelemeli aşamaya böler: İş Problemi → Veriyi Tanıma → Veri Hazırlama → Modelleme → Değerlendirme → Deployment. Aşağıdaki bölümler bu aşamaları sırayla aktarmaktadır.

4. Keşifsel Veri Analizi (EDA)

Veri seti yedi aşamalı sistematik bir keşif sürecinden geçirilmiştir. İlk tespit, verinin kalitesinin yüksek olduğudur: eksik değer, mükerrer kayıt veya mantıksal tutarsızlık bulunmamaktadır. Bu, sağlam bir analitik temel oluşturmaktadır.

En Önemli Bulgular

- Yaş, churn'ün en güçlü öngörücüsüdür ($r = +0,285$). Ayrılan müşterilerin ortalama yaşı 45,6 iken kalanların ortalaması 37,1'dir; 65 yaş üstü grupta churn oranı %60'a ulaşmaktadır.
- Pasif üyeler aktiflere göre iki kat fazla ayrılmaktadır: aktif üyelerde churn %13,4 iken pasif üyelerde %27,5'tir.
- Coğrafya sistemik bir risk taşımaktadır: Fransa ve İspanya'da churn ~%17-18 iken Almanya'da %28,8'dir.
- Ürün sayısı sezgiye aykırı, doğrusal olmayan güçlü bir sinyal üretir: 1-2 ürünü olan müşterilerde churn %18-20 iken, 3-4 ürünü olanlarda %63-66'ya fırlamaktadır.
- CreditScore, Tenure ve EstimatedSalary değişkenleri churn'ü anlamlı biçimde açıklamamaktadır (Mann-Whitney U testi, $p > 0,05$).

Bu bulgular yalnızca teknik gözlemler değil, doğrudan iş anlamı taşıyan içgörülerdir. Özellikle **çok ürünlü müşterilerdeki yüksek churn** bulgusu, bankanın çapraz satış (cross-sell) stratejisini gözden geçirmesi gerektiğine işaret eden, sunumda öne çıkarılması gereken bir tespittir.

Görsel ekleme notu: Bu bölüme projedeki figures/ klasöründen yaş-churn dağılımı, ülke bazlı churn ve ürün sayısı-churn grafiklerini ekleyiniz (örn. ekran görüntüsü olarak yapıştırın).

5. Veri Hazırlama (Data Preparation)

Veri hazırlama aşaması, EDA bulguları temel alınarak ve veri sızıntısı titizlikle önlenerek yürütülmüştür. Anlamsız kimlik değişkenleri (RowNumber, CustomerId, Surname) modelden çıkarılmıştır. Kategorik değişkenlerden Geography one-hot encoding (ilk kategori düşürülerek), Gender ikili kodlama ile sayısallaştırılmıştır. Beş sayısal değişken StandardScaler ile ölçeklenmiştir.

Özellik Mühendisliği (Feature Engineering)

EDA bulgularını modele aktarmak için iki yeni değişken türetilmiştir. is_high_products_risk (3 veya daha fazla ürün) değişkeni, referans gruba göre 3,4 kat daha yüksek churn sinyali (%63,9'a karşı %18,8) taşımaktadır. has_zero_balance değişkeni ise bakiyesi sıfır olan müşterileri (%35,4) işaretler. Bu adım, “veriyi yalnızca temizlemedik, içgörülerini modele akıllıca taşıdık” anlayışını yansıtır.

Sızıntı Önleme ve Veri Bölme

Tüm ön işleme adımları bir scikit-learn Pipeline ve ColumnTransformer yapısı içinde tanımlanmıştır. Pipeline yalnızca eğitim kümesi (8.000 gözlem) üzerinde fit edilmiş, test kümesine (2.000 gözlem) yalnızca transform uygulanmıştır. Bu yaklaşım, test bilgisinin eğitime sızmasını (data leakage) engelleyen kritik bir tekniktir. Veri, %80/%20 oranında ve stratified (katmanlı) biçimde bölünmüş; böylece churn oranı hem eğitim (%20,28) hem test (%20,25) kümelerinde korunmuştur.

Sınıf Dengesizliğinin Yönetimi

Yaklaşık %20'lik hafif dengesizlik için yapay örnekleme (SMOTE) yerine class_weight stratejisi tercih edilmiştir; bu, daha güvenli ve veriyi yapay verilerle bozmayan bir yaklaşımdır. Sınıf ağırlıkları ters frekansla hesaplanmıştır (sınıf 0 → 0,627; sınıf 1 → 2,467). Ağaç tabanlı modeller için scale_pos_weight ve is_unbalance gibi eşdeğer parametreler kullanılmıştır. Nihai özellik seti 13 değişkenden oluşmaktadır ve veri modellemeye hazırdır.

6. Modelleme ve Model Karşılaştırması

Modelleme aşamasında, baseline modeller dahil olmak üzere 16 farklı sınıflandırma algoritması aynı veri bölünmesi ve aynı metrik stratejisiyle eğitilip karşılaştırılmıştır. Sınıf dengesizliği nedeniyle ana değerlendirme metrikleri accuracy değil, F1 skoru ve Recall olarak belirlenmiştir; ayrıca ROC-AUC, Precision ve Accuracy de raporlanmıştır.

Model seçimi tek bir skora dayandırılmamış, çok kriterli bir puanlama kullanılmıştır: F1 (0,35) + Recall (0,25) + ROC-AUC (0,20) + çapraz doğrulama kararlılığı (0,10) + overfitting cezası (0,10). Bu yaklaşım, yalnızca en yüksek skoru değil, en güvenilir ve genellenebilir modeli seçmeyi amaçlar.

Nihai Model: Lojistik Regresyon

Metrik	Değer
Test F1	0,4866
Recall (yakalama oranı)	0,6716 — tüm modeller içinde en yüksek
Precision	0,3815
ROC-AUC	0,7629 — tüm modeller içinde en yüksek

Overfitting farkı (train-test)

+0,0103 — neredeyse sıfır

Lojistik Regresyon, hem en yüksek Recall hem en yüksek ROC-AUC değerine sahip olan ve overfitting göstermeyen tek modeldir. Buna karşılık Random Forest, Extra Trees ve Bagging modelleri eğitim kümesinde $F1 = 1,000$ ile veriyi **ezberlemiş (ağır overfitting)**; Gradient Boosting, AdaBoost ve XGBoost ise yüksek Precision'a karşın düşük Recall (0,22–0,25) üreterek ayrılacak müşterilerin büyük kısmını kaçırmıştır. İş probleminde yanlış negatif maliyeti yüksek olduğundan, Recall önceliğiyle Lojistik Regresyon'un seçilmesi metodolojik olarak doğru karardır.

Görsel ekleme notu: Buraya figures/ klasöründen 16 model performans karşılaştırma grafiğini ve ROC eğrilerini ekleyiniz. Tam karşılaştırma için reports/csv/ranked_model_results.csv tablosu kullanılabilir.

7. Değerlendirme ve Hata Analizi

Nihai modelin test kümesindeki (2.000 müşteri) performansı, confusion matrix üzerinden iş bağlamına çevrilerek yorumlanmıştır.

	Tahmin: Ayrılır	Tahmin: Kalır
Gerçek: Ayrıldı	272 (Doğru yakalama)	133 (Kaçırılan — kritik)
Gerçek: Kaldı	441 (Yanlış alarm)	1.154 (Doğru)

Model, gerçek 405 churn vakasının 272'sini önceden yakalamaktadır (Recall %67,2). Kaçırılan 133 müşteri (yanlış negatif), iş açısından en maliyetli hata grubudur; bu müşteriler hiçbir müdahale görmeden kaybedilir. 441 yanlış alarm (yanlış pozitif) ise görece düşük maliyetlidir: bu müşterilere gereksiz bir elde tutma teklifi sunulur, o kadar. Bu denge, projenin başında belirlenen “yanlış negatif daha maliyetlidir” ilkesiyle uyumludur.

İyileştirme fırsatı: Karar eşiği 0,50'den 0,40'a düşürülürse Recall %72-75 bandına çıkarılabilir; bu, daha fazla riskli müşteriyi yakalamak pahasına yanlış alarm sayısını artırır. Bankanın elde tutma bütçesine göre bu eşik ayarlanabilir.

8. Deployment (Ürünleştirme)

Nihai model ve ön işleme pipeline'ı joblib ile kaydedilmiş ve Streamlit tabanlı, çalışan bir web arayüzüne dönüştürülmüştür. Bu, projenin yalnızca bir notebook analizi olmadığını; gerçek bir kullanıcının veri girip anlık tahmin alabildiği bir karar destek aracına ulaştığını gösterir.

Uygulama altı sekmeden oluşur ve hem tekil tahmin (form ile tek müşteri) hem toplu tahmin (CSV yükleyerek çoklu müşteri) sunar. Kullanıcı 10 ham alan girer; is_high_products_risk ve has_zero_balance değişkenleri arka planda otomatik türetilir. Sonuç, churn olasılığı, risk etiketi (Düşük/Orta/Yüksek) ve bir güven skoru göstergesiyle sunulur. Yapılan duman testinde (smoke test) düşük riskli profil %18,0, yüksek riskli profil %98,7 churn olasılığı üretmiş; model tutarlı çalışmaktadır.

Arayüz tasarımı Shneiderman'ın 8 Altın Kuralı uygulanmıştır: tutarlı renk ve bileşen dili, sık kullanıcılar için örnek/kısayol butonları, her işlemde bilgilendirici geri bildirim, girdi ve CSV

doğrulamasıyla hata önleme, sıfırlama/temizleme ile geri alınabilirlik, sabit kenar çubuğuyla kontrol hissi ve yardım sekmesiyle bellek yükünün azaltılması.

9. Riskler ve Sınırlılıklar

Modelin sınırlılıkları dürüstçe raporlanmaktadır. En iyi modelin dahi F1 skoru ~0,49 düzeyindedir; bu, veri setindeki sinyalin sınırlı olduğunu ve modelin churn vakalarının yalnızca bir kısmını ayırt edebildiğini gösterir. Bu durum bir başarısızlık değil, gerçekçi bir tablodur: aşırı yüksek (örn. %99) bir skor, çoğu zaman veri sızıntısının işaretidir.

- Model bir karar destek aracıdır; nihai kararlar uzman değerlendirmesiyle birlikte alınmalıdır.
- Düşük güvenli tahminler ayrıca işaretlenmeli ve dikkatle ele alınmalıdır.
- Üretim ortamında model performansı zamanla düşebilir (model drift); periyodik olarak yeniden eğitilmelidir.
- Cinsiyet ve coğrafya gibi hassas değişkenlerin kullanımı, etik ve adalet açısından gözden geçirilmelidir.

10. Sonuç ve Karar Önerileri

Bu proje, ham veriden çalışan bir karar destek aracına uzanan bütüncül bir makine öğrenmesi sürecini başarıyla tamamlamıştır. Geliştirilen model, ayrılma riski yüksek müşterileri makul bir doğrulukla önceden tespit ederek bankaya proaktif hareket etme imkânı sunar.

Bankaya Öneriler

- Yaşı yüksek, pasif ve Almanya'daki müşteriler öncelikli izleme grubuna alınmalı; bu segmentlere özel elde tutma kampanyaları tasarlanmalıdır.
- Üç ve dört ürünlü müşterilerdeki anormal yüksek churn acilen incelenmelidir; bu, ürün paketleme veya fiyatlandırma kaynaklı bir memnuniyetsizliğe işaret edebilir.
- Model çıktısı, pazarlama bütçesinin en riskli müşterilere yönlendirilmesinde önceliklendirme aracı olarak kullanılmalıdır.
- Karar eşiği, bankanın elde tutma bütçesi ve risk iştahına göre ayarlanmalı; bütçe genişse Recall'ı artıracak şekilde düşürülmelidir.

Özetle: model kurmak başlangıçtır; asıl değer, bu modeli iş bağlamına oturtup somut bir karara hizmet eden bir araca dönüştürmektir. Bu çalışma tam da bunu hedeflemiştir.